

Clasificación de régimen de mercado mediante representaciones tiempo–frecuencia y redes convolucionales

Sofía Belén Caselli Gaspar Rivollier Miguel Ángel Leiva Martínez
Especialización en Inteligencia Artificial
Universidad de Buenos Aires (FIUBA) — Buenos Aires, Argentina

Resumen—Se aborda la predicción de señales de *trading* (comprar, mantener, vender) transformando la serie temporal de precios en imágenes tiempo–frecuencia y procesándolas con redes neuronales convolucionales (CNN). Sobre un universo multi–activo (criptomonedas, acciones, materias primas y divisas) se generan dos representaciones de cada ventana de 60 días: el espectrograma de Fourier de tiempo corto (STFT) y el escalograma *wavelet* de Morlet continua. Las etiquetas se construyen con un umbral adaptativo basado en el *Average True Range* (ATR) y se reserva el año 2026 como conjunto de prueba estrictamente fuera de muestra. Se comparan cuatro modelos bajo idénticas condiciones (CNN propia y ResNet–18 preentrenada, cada una con STFT y *wavelet*), evaluados con *balanced accuracy* y F1–macro para evitar el sesgo del desbalance de clases. La mejor combinación, ResNet–18 sobre STFT, alcanza un F1–macro de 0,369 y *balanced accuracy* de 37,4 %, superando el azar (0,333) y al resto de las configuraciones. Los resultados muestran que (i) el *transfer learning* domina a la CNN entrenada desde cero y (ii) la STFT captura mejor la señal direccional que el escalograma *wavelet* en esta tarea. La señal predictiva existe pero es débil, lo que constituye un hallazgo honesto sobre los límites del enfoque puramente visual en mercados financieros.

Index Terms—series temporales financieras, STFT, transformada *wavelet* continua, redes convolucionales, transfer learning, clasificación de régimen de mercado.

I. INTRODUCCIÓN

La predicción de la dirección de los mercados financieros es un problema clásico por su relevancia económica y su dificultad: las series de precios son no estacionarias, ruidosas y con baja relación señal–ruido. Una línea de trabajo creciente propone *re–encuadrar* el problema como uno de visión por computadora, convirtiendo la serie en una imagen y delegando la extracción de patrones a una CNN, en analogía con el análisis gráfico ("técnico") tradicional.

Este trabajo explora esa hipótesis con representaciones *tiempo–frecuencia*, que exponen explícitamente cómo evoluciona el contenido frecuencial del precio a lo largo del tiempo. La motivación productiva es generar señales de *trading* accionables (BUY/HOLD/SELL) a partir de patrones visuales en la dinámica de frecuencias.

A diferencia de una representación puramente temporal, un mapa tiempo–frecuencia hace explícita la coexistencia de ciclos de distinta duración: tendencias de mediano plazo (bajas frecuencias) y oscilaciones rápidas o *shocks* (altas frecuencias). La hipótesis de trabajo es que los regímenes de mercado — alcista, lateral, bajista — dejan una *firma* reconocible

en este plano, y que una CNN, sin ingeniería de *features* manual, puede aprender a discriminarla. La elección de *qué* representación tiempo–frecuencia usar (Fourier vs. *wavelet*) no es neutral: cada una impone un compromiso distinto entre resolución temporal y frecuencial, lo que motiva el *ablation* central de este estudio.

I-A. Estado del arte

El uso de CNN sobre imágenes de mercado fue popularizado por Sezer y Ozbayoglu [1], quienes codifican indicadores técnicos en una grilla 2D (*CNN–TA*) y entrenan una CNN para emitir señales de compra/venta, obteniendo resultados competitivos frente a estrategias *buy-and-hold*. Más recientemente, Cohen *et al.* [2] y diversos trabajos sobre *Gramian Angular Fields* [3] confirman que la transformación serie–a–imagen permite reutilizar arquitecturas de visión preentrenadas. En el dominio tiempo–frecuencia, el escalograma *wavelet* ha mostrado ventajas para detectar eventos transitorios (*crashes*, picos) gracias a su resolución adaptativa [4]. Nuestra contribución es un *ablation* controlado que enfrenta STFT contra *wavelet* de Morlet bajo idénticas condiciones de entrenamiento y evaluación, sobre un universo multi–activo y con un protocolo temporal estricto (test = 2026).

I-B. Contribuciones

- Un *pipeline* reproducible que genera, para cada activo, dos datasets de imágenes (STFT y *wavelet*) con etiquetas idénticas.
- Un etiquetado BUY/HOLD/SELL con umbral adaptativo por ATR escalado con la raíz del horizonte temporal.
- Una comparación de cuatro modelos y un barrido de horizontes, reportando métricas robustas al desbalance de clases.

II. METODOLOGÍA

II-A. Datos y preprocesamiento

Se descargan precios diarios ajustados vía *yfinance* desde 2022-01-01. El universo cubre cuatro clases de activo: criptomonedas, acciones, materias primas y divisas. Para cada activo se calcula la serie de retornos logarítmicos $r_t = \log(P_t/P_{t-1})$, estacionaria y aditiva, y se la normaliza por *z-score*. Cada muestra es una ventana deslizante de $W = 60$ días.

II-B. Representaciones tiempo–frecuencia

A partir de cada ventana se generan dos imágenes de 64×64 píxeles (mapa de color *magma*, frecuencias bajas abajo):

- **STFT**: espectrograma con ventana de Hann de 32 muestras, solapamiento de 28 y $nfft=64$. Resolución tiempo–frecuencia fija.
- **Wavelet**: transformada *wavelet* continua con Morlet compleja $cmor1.5-1.0$ y escalas de 2 a 30 días. Resolución adaptativa, mejor para transitorios.

Ambos datasets comparten exactamente las mismas etiquetas, lo que permite un *ablation* limpio de la representación. La Fig. 1 ilustra ambas transformaciones sobre una misma ventana de precio: la STFT ofrece una grilla tiempo–frecuencia de resolución uniforme, mientras que el escalograma *wavelet* concentra mayor detalle en los eventos transitorios (la caída del precio se refleja en la activación de las escalas correspondientes).

II-C. Etiquetado adaptativo

La etiqueta de cada muestra depende del retorno futuro acumulado a h días y de un umbral proporcional a la volatilidad local, medida con el ATR:

$$\text{label} = \begin{cases} \text{BUY} & \text{si } R_h > +\tau_h \\ \text{SELL} & \text{si } R_h < -\tau_h \\ \text{HOLD} & \text{en otro caso} \end{cases} \quad (1)$$

con $\tau_h = k \cdot \text{ATR} \cdot \sqrt{h}$ y $k = 0,7$. El factor $\sqrt{h}$ refleja que la volatilidad crece con la raíz del tiempo. El umbral k se ajustó para mitigar el dominio de la clase HOLD. Un valor inicial de $k = 1,3$ producía una distribución degenerada ($\sim 90\%$ HOLD) que inducía el colapso del clasificador a la clase mayoritaria; reducirlo a $k = 0,7$ equilibró la distribución a aproximadamente 17%/68%/15% (BUY/HOLD/SELL), sin dejar de respetar la semántica de volatilidad del ATR. Este ajuste ilustra cómo el diseño del etiquetado, y no sólo el modelo, condiciona fuertemente el aprendizaje en problemas financieros.

II-D. Protocolo de evaluación

El *split* es estrictamente cronológico para evitar fuga temporal: entrenamiento y validación dentro de 2022–2025 (validación = últimos meses), y **2026 completo como test fuera de muestra**. El conjunto resultante tiene aproximadamente 6.700 muestras (train 4.690, val 1.496, test 523 para el horizonte de 7 días).

II-E. Modelos y entrenamiento

Se comparan dos arquitecturas:

- **CNN propia**: cuatro bloques convolucionales (Conv–BN–ReLU $\times 2$ –MaxPool–Dropout), $\sim 1,45$ M de parámetros, entrenada desde cero.
- **ResNet–18**: backbone preentrenado en ImageNet (*transfer learning*) con cabeza densa de tres clases, $\sim 11,24$ M de parámetros.

Cuadro I
COMPARACIÓN DE MODELOS (TEST 2026, HORIZONTE 7 DÍAS).

Modelo	Repr.	Acc %	Bal-Acc %	F1-macro	Params
ResNet–18	STFT	62,33	37,43	0,369	11,24 M
ResNet–18	Wavelet	51,24	30,42	0,305	11,24 M
CNN propia	STFT	25,24	36,42	0,243	1,45 M
CNN propia	Wavelet	16,63	38,00	0,167	1,45 M
Azar (3 clases)		33,3	33,3	0,333	—

Cuadro II
BARRIDO DE HORIZONTES (RESNET–STFT, TEST 2026).

Horizonte (d)	Acc %	Bal-Acc %	F1-macro
7	62,33	37,43	0,369
15	51,63	35,62	0,342
30	61,95	35,05	0,338

El desbalance de clases se ataca con doble mecanismo: *Weighted Random Sampler* y *Cross Entropy* ponderada por el inverso de la frecuencia, con *label smoothing* 0,05. Optimizador AdamW ($\text{lr} = 3 \times 10^{-4}$, *weight decay* 10^{-4}), *ReduceLROnPlateau*, *early stopping* sobre F1–macro de validación y *gradient clipping*. Todos los experimentos comparten semilla, épocas, transformaciones y *split*, garantizando *idénticas condiciones*.

III. RESULTADOS

III-A. Comparación de modelos

La Tabla I resume las cuatro combinaciones sobre el test 2026, ordenadas por F1–macro. Dado el fuerte desbalance (HOLD $\approx 68\%$), la *accuracy* cruda es engañosa; las métricas principales son *balanced accuracy* y F1–macro.

III-B. Ablation de representación

En ambas arquitecturas la STFT supera al escalograma *wavelet* (ResNet: 0,369 vs. 0,305; CNN: 0,243 vs. 0,167). Pese a la mejor resolución del *wavelet* para transitorios, la STFT aporta mayor señal direccional global en esta tarea.

III-C. Barrido de horizontes

Sobre el modelo ganador (ResNet–STFT) se evaluaron tres horizontes (Tabla II). El horizonte corto (7 días) maximiza el F1–macro; ampliar el horizonte degrada levemente el desempeño.

III-D. Análisis por clase

La Tabla III detalla el reporte de clasificación del mejor modelo (ResNet–STFT, 7 días) sobre el test 2026. El modelo identifica bien la clase mayoritaria HOLD (*recall* 0,81) pero tiene dificultad con las señales accionables BUY (*recall* 0,26) y especialmente SELL (*recall* 0,06). Esto indica que la mayor parte de la ganancia sobre el azar proviene de detectar la *ausencia* de señal direccional fuerte más que de anticipar el sentido del movimiento.




Figura 1. De serie de precios a imagen tiempo–frecuencia. Izquierda: ventana de 60 días del precio de cierre. Centro: espectrograma STFT (resolución fija). Derecha: escalograma *wavelet* de Morlet (resolución adaptativa). Ambas se redimensionan a 64×64 con mapa *magma* como entrada a la CNN.



Figura 2. F1–macro y *balanced accuracy* por modelo. La línea punteada marca el azar (0,33).




Figura 3. Desempeño de ResNet–STFT según el horizonte de predicción. El horizonte de 7 días maximiza el F1–macro y la *balanced accuracy*.

III-E. Interpretabilidad

Se aplicó Grad–CAM sobre la última capa convolucional del modelo ganador para identificar qué regiones del espectrograma motivan cada decisión. Las activaciones se concentran predominantemente en las bandas de *baja frecuencia* (parte inferior de la imagen, ciclos largos), lo que es consistente con el predominio de la componente tendencial del precio por

Cuadro III
REPORTE POR CLASE — RESNET–STFT, HORIZONTE 7 DÍAS, TEST 2026.

Clase	Precision	Recall	F1	Soporte
BUY	0,282	0,256	0,268	78
HOLD	0,721	0,812	0,764	372
SELL	0,121	0,055	0,075	73
<i>macro avg</i>	0,375	0,374	0,369	523
<i>weighted avg</i>	0,572	0,623	0,594	523

sobre el ruido de alta frecuencia. Este comportamiento sugiere que la red aprende a leer la inercia de mediano plazo de la serie más que oscilaciones rápidas, alineado con la intuición del análisis técnico tradicional.

III-F. Costo computacional

La CNN propia (1,45 M de parámetros) es casi un orden de magnitud más liviana que ResNet–18 (11,24 M), pero su menor capacidad y la falta de preentrenamiento la dejan por debajo en todas las métricas. El compromiso costo–desempeño favorece claramente al *transfer learning* en este problema: el sobrecosto de ResNet se traduce en una mejora de F1–macro de +0,126 con STFT.

IV. DISCUSIÓN Y LIMITACIONES

Los resultados deben leerse con cautela. En primer lugar, la métrica *accuracy* resulta profundamente engañosa bajo el desbalance observado: un clasificador trivial que prediga siempre HOLD obtendría $\sim 68\%$ de *accuracy* y, sin embargo, sería inútil como sistema de *trading*. Por ello todo el análisis se ancla en *balanced accuracy* y F1–macro, que penalizan explícitamente ignorar a las clases minoritarias.

En segundo lugar, la superioridad de la STFT sobre el escalograma *wavelet* puede deberse en parte a la dimensión y el preprocesamiento de las imágenes (64×64 , reescaladas): a esa resolución, la ventaja de localización del *wavelet* para transitorios podría diluirse. No puede descartarse que con mayor resolución, o combinando ambas representaciones en canales separados, el balance cambie.

En tercer lugar, el conjunto de prueba (2026) corresponde a un único año y a un régimen de mercado particular; la generalización temporal a otros períodos no está garantizada. Asimismo, la evaluación es puramente de clasificación y no incorpora costos de transacción ni un *backtesting* económico, por lo que un F1-macro superior al azar no implica automáticamente rentabilidad.

Finalmente, la dificultad para predecir BUY y SELL es coherente con la hipótesis de eficiencia de mercado: si la dirección futura fuese fácilmente legible en el espectrograma, la oportunidad de arbitraje se cerraría rápidamente. El valor del trabajo radica, entonces, no en una promesa de rentabilidad sino en cuantificar de forma controlada *cuánta* señal direccional es extraíble por métodos visuales, y en establecer un protocolo reproducible para futuras mejoras.

V. CONCLUSIONES

1. **El *transfer learning* es decisivo:** ResNet-18 preentrenada supera ampliamente a la CNN entrenada desde cero (F1-macro 0,369 vs. 0,243 con STFT), pese a la diferencia de dominio entre ImageNet y los espectrogramas financieros.
2. **STFT > Wavelet en esta tarea:** la representación de Fourier captura mejor la señal direccional global, superando al escalograma de Morlet en ambas arquitecturas.
3. **Horizonte corto preferible:** 7 días maximiza el F1-macro; horizontes mayores no mejoran y tienden a degradar.
4. **La señal existe pero es débil:** la *balanced accuracy* del 37,4 % supera el azar (33,3 %) de forma modesta; las clases BUY/SELL son difíciles de detectar, lo que delimita honestamente el alcance del enfoque visual.
5. **La evaluación honesta es imprescindible:** una *accuracy* cruda del 62 % oculta el colapso a la clase mayoritaria; sólo *balanced accuracy* y F1-macro revelan el desempeño real, y deben ser el criterio en datasets desbalanceados.

Como trabajo futuro se proponen: *focal loss* para reforzar las clases minoritarias, fusión de ambas representaciones en canales separados, horizontes intradía y validación con *backtesting* económico.

REFERENCIAS

- [1] O. B. Sezer and A. M. Ozbayoglu, "Algorithmic financial trading with deep convolutional neural networks: Time series to image conversion approach," *Applied Soft Computing*, vol. 70, pp. 525–538, 2018.
- [2] N. Cohen, T. Balch, and M. Veloso, "Trading via image classification," in *Proc. ACM Int. Conf. on AI in Finance (ICAIF)*, 2020.
- [3] Z. Wang and T. Oates, "Imaging time-series to improve classification and imputation," in *Proc. IJCAI*, 2015, pp. 3939–3945.
- [4] C. Torrence and G. P. Compo, "A practical guide to wavelet analysis," *Bulletin of the American Meteorological Society*, vol. 79, no. 1, pp. 61–78, 1998.